

Reconocimiento de emociones en el habla mediante características acústicas expertas y representaciones autosupervisadas multicapa

Alejandro García Giacchetta Franco Sandri
I302 Aprendizaje Automático y Aprendizaje Profundo
Universidad de San Andrés
Buenos Aires, Argentina

Resumen—El reconocimiento automático de emociones en el habla debe distinguir patrones afectivos sin depender de la identidad del hablante. Este trabajo compara características acústicas expertas eGeMAPSv02 con representaciones autosupervisadas wav2vec 2.0 sobre RAVDESS, bajo una evaluación estrictamente independiente de hablante. Se analizaron Random Forest, regresión logística, perceptrón multicapa y cuatro estrategias de agregación temporal multicapa. La mejor configuración promedió, entre los 13 niveles del encoder congelado, la media y el desvío temporal de sus representaciones, y utilizó una regresión logística como clasificador. Alcanzó una *balanced accuracy* de 0.736 ± 0.049 en validación cruzada y 0.828 sobre cuatro actores de test no vistos. RFECV no mejoró el rendimiento respecto de la representación completa y mostró inestabilidad entre folds. Las variantes con mezcla aprendida y atención temporal tampoco mejoraron la generalización. En transferencia zero-shot hacia RAVDESS Song y EMO-DB, wav2vec superó a eGeMAPS; además, la adaptación exclusiva de la cabeza logística incrementó el rendimiento target manteniendo congelado el extractor, con una caída moderada en el dominio fuente. Los resultados muestran que una representación SSL rica, combinada con un clasificador simple, constituye una solución efectiva y estable para conjuntos SER de tamaño reducido.

Index Terms—reconocimiento de emociones en el habla, eGeMAPS, wav2vec 2.0, aprendizaje autosupervisado, speaker-independent, transferencia de dominio

I. INTRODUCCIÓN

El reconocimiento de emociones en el habla (SER, *Speech Emotion Recognition*) busca inferir el estado afectivo expresado en una señal vocal. Sus aplicaciones incluyen interfaces humano-computadora, asistencia clínica, análisis de llamadas y sistemas adaptativos. La tarea es difícil porque la prosodia, la energía, la calidad vocal y el contenido espectral están simultáneamente afectados por emoción, identidad, sexo, texto e intensidad. En particular, un modelo puede obtener resultados optimistas si escucha durante el entrenamiento a los mismos hablantes que luego aparecen en evaluación.

La entrada del sistema desarrollado es un archivo de audio con una emisión completa y la salida es una de ocho emociones de RAVDESS: neutral, calma, alegría, tristeza, enojo, miedo, disgusto o sorpresa. Se compararon dos familias de representación. La primera utiliza eGeMAPSv02, un conjunto compacto de descriptores acústicos diseñados para voz y computación afectiva [1]. La segunda utiliza embeddings de wav2vec 2.0, un encoder autosupervisado entrenado sobre

grandes volúmenes de habla no etiquetada [2]. Estudios previos muestran que estos embeddings pueden transferirse a SER con modelos superficiales y mezclas entre capas [3], mientras que comparaciones recientes destacan la dependencia del rendimiento respecto del corpus, las features y el protocolo de evaluación [4].

El aporte principal consiste en una comparación controlada bajo el mismo protocolo independiente de hablante. Se estudian modelos clásicos, refinamientos supervisados y representaciones temporales multicapa, incluyendo mezclas aprendidas y atención. Finalmente, se evalúa el cambio de dominio hacia canto emocional y otro corpus de habla, separando la calidad de la representación de la adaptación del clasificador.

II. CONJUNTO DE DATOS Y CARACTERÍSTICAS

II-A. RAVDESS Speech y preprocesamiento

RAVDESS contiene grabaciones audiovisuales de 24 actores profesionales, balanceados por sexo, que producen expresiones emocionales con frases léxicamente coincidentes [5]. Se empleó únicamente la modalidad de habla en audio, con 1440 archivos y las ocho clases indicadas. Neutral posee 96 ejemplos y las otras emociones 192, debido a que neutral no incluye intensidad fuerte.

Cuadro I: Particiones del experimento principal

Partición	Actores	Audios	Uso
Development	20	1200	selección y validación
Test	4	240	evaluación final

Los audios fueron convertidos a mono promediando canales, preservando igual importancia cuando existían canales duplicados. Se mantuvo la frecuencia original de 48 kHz para el análisis acústico y se remuestreó a 16 kHz para wav2vec. El silencio inicial y final se recortó mediante energía RMS en ventanas de 25 ms y saltos de 10 ms, con umbral relativo de -35 dB y 150 ms de margen. No se aplicó normalización RMS por archivo, ya que la dinámica de amplitud puede contener información emocional.

II-B. Representaciones acústicas

Con openSMILE [6] se extrajeron los 88 *functionals* de eGeMAPSv02. Incluyen medidas de frecuencia fundamental,

energía, calidad vocal, formantes, MFCC y estadísticas espectrales. Estas variables forman un vector global por emisión y ofrecen una descripción acústica interpretable.

Para la representación SSL se utilizó `facebook/wav2vec2-base` con el encoder congelado. Se almacenaron la proyección inicial y las doce capas Transformer, cada una con dimensión $D = 768$. Para un audio i , cada nivel l produce una secuencia $H_i^{(l)}$. La representación seleccionada calcula media y desvío a lo largo del tiempo en cada nivel y luego promedia ambas estadísticas entre los $L = 13$ niveles:

$$z_i = \left[\frac{1}{L} \sum_{l=1}^L \mu(H_i^{(l)}), \frac{1}{L} \sum_{l=1}^L \sigma(H_i^{(l)}) \right]. \quad (1)$$

El resultado tiene 1536 componentes. Esta operación conserva información sobre tendencia central y variabilidad temporal sin introducir parámetros entrenables en el pooling.

III. METODOLOGÍA

III-A. Protocolo experimental

Los actores 2, 6, 21 y 23 se reservaron como test, con dos voces femeninas y dos masculinas. Los 20 actores restantes se utilizaron en una validación cruzada `StratifiedGroupKFold` de cinco folds, agrupando por actor y estratificando por emoción. Cada fold contiene hablantes completos; por lo tanto, ningún modelo se valida con identidades presentes en su entrenamiento. Todos los transformadores, escaladores y selectores se ajustaron únicamente con el train de cada fold. Las decisiones se tomaron en development y el test se abrió una sola vez.

La métrica principal fue `balanced accuracy` (BA), equivalente al promedio no ponderado de recall cuando todas las clases están presentes:

$$BA = \frac{1}{K} \sum_{k=1}^K \frac{TP_k}{TP_k + FN_k}. \quad (2)$$

Se reportaron además `macro-F1`, `accuracy`, `precisión` y `recall`. BA fue priorizada porque neutral contiene la mitad de ejemplos y porque cada emoción debe contribuir por igual a la selección.

III-B. Modelos y refinamientos

Los baselines y proyecciones se implementaron con `scikit-learn` [7]; las redes temporales se entrenaron con `PyTorch` [8], y el checkpoint SSL se obtuvo mediante `Transformers` [9]. El baseline obligatorio fue `Random Forest` con 300 árboles, `min_samples_leaf=2` y pesos de clase balanceados [10]. Se evaluó también regresión logística L2 ($C = 1$) y un MLP con capas ocultas 128–64, ReLU, Adam, `learning rate` 10^{-3} , `batch 32` y `early stopping`. Para eGeMAPS y `wav2vec` global se probaron PCA, RFECV y LDA con `shrinkage`; todas las operaciones supervisadas se ajustaron dentro del fold.

Sobre las secuencias multicapa se compararon cuatro formas de transformar una señal de longitud variable en un vector global. La configuración fija `average_mean_std`, definida

en Ecuación 1, calcula estadísticas temporales por nivel y luego las promedia. En `learned_layers_mean_std`, cada nivel aporta un vector $s_i^{(l)} = [\mu_i^{(l)}; \sigma_i^{(l)}]$, estandarizado con parámetros calculados exclusivamente sobre el train del fold. La contribución relativa de cada nivel se obtiene mediante logits entrenables a_l :

$$\beta_l = \frac{\exp(a_l)}{\sum_{j=1}^L \exp(a_j)}, \quad z_i^{\text{stat}} = \sum_{l=1}^L \beta_l \tilde{s}_i^{(l)}. \quad (3)$$

Los coeficientes β_l son escalares, no pesos por feature: indican cuánto contribuye globalmente cada nivel de `wav2vec` al resumen estadístico. Después de la mezcla se aplican `LayerNorm`, dropout y una cabeza lineal. Así, el modelo aprende qué niveles de abstracción acústica y contextual resultan más útiles, pero mantiene una representación final de 1536 componentes.

Las variantes con atención cambian el orden de las operaciones. Primero combinan los hidden states frame-level:

$$u_{i,t} = \sum_{l=1}^L \gamma_l h_{i,t}^{(l)}, \quad \gamma_l = \frac{1}{L} \text{ o } \gamma_l = \text{softmax}(a)_l, \quad (4)$$

según se use promedio uniforme o mezcla aprendida. Luego una red pequeña asigna un score a cada frame y lo normaliza únicamente sobre los frames válidos:

$$e_{i,t} = w_2^\top \tanh(W_1 u_{i,t} + b_1) + b_2, \quad \alpha_{i,t} = \frac{\exp(e_{i,t})}{\sum_{\tau \in \mathcal{T}_i} \exp(e_{i,\tau})}. \quad (5)$$

Los pesos temporales $\alpha_{i,t}$ determinan qué regiones de la emisión contribuyen al resumen final. El pooling atento concatena la media y el desvío ponderados:

$$\mu_i^\alpha = \sum_{t \in \mathcal{T}_i} \alpha_{i,t} u_{i,t}, \quad \sigma_i^\alpha = \sqrt{\max \left\{ \sum_{t \in \mathcal{T}_i} \alpha_{i,t} (u_{i,t} - \mu_i^\alpha)^2, \varepsilon \right\}}. \quad (6)$$

Por lo tanto, los pesos de capa γ_l operan sobre niveles de representación acústico-contextual, mientras que $\alpha_{i,t}$ pondera instantes temporales; ninguno asigna pesos directos a dimensiones individuales del embedding. `average_attention_statistics` usa $\gamma_l = 1/L$, mientras que `learned_layers_attention_statistics` aprende simultáneamente γ_l , la atención temporal y la cabeza clasificadora.

Para `learned_layers_mean_std`, cada componente estadística se estandarizó usando exclusivamente el outer train:

$$\tilde{s}_{i,c}^{(l)} = \frac{s_{i,c}^{(l)} - m_c^{(l)}}{q_c^{(l)}}, \quad (7)$$

donde $m_c^{(l)}$ y $q_c^{(l)}$ son la media y el desvío de la componente c del nivel l . La mezcla de la Ecuación 3 utiliza un único peso

por nivel para las componentes de media y desvío, lo que evita aprender una ponderación independiente para cada una de las 1536 dimensiones.

En las variantes atentas, $\mathcal{T}_i$ en las Ecuación 5 y Ecuación 6 contiene solamente frames reales. Los frames de padding se enmascaran antes del softmax y no contribuyen al pooling. La representación final es

$$z_i^{\text{att}} = [\mu_i^\alpha; \sigma_i^\alpha] \in \mathbb{R}^{1536}, \quad (8)$$

y luego atraviesa *LayerNorm*, dropout y una proyección lineal a las ocho clases. La diferencia central entre las cuatro configuraciones es el punto en el que se aprende la ponderación: después del resumen temporal en `learned_layers_mean_std`, o antes de calcular las estadísticas en las dos variantes con atención. Las variantes atentas emplearon 64 unidades internas, dropout 0.5, batch 16, máximo 100 épocas y paciencia 10. Se repitieron con semillas 13, 42 y 73, y se evaluó el ensemble de probabilidades.

III-C. Transferencia de dominio

Se evaluó el modelo sobre RAVDESS Song y EMO-DB [11]. Primero se realizó transferencia zero-shot sin modificar el pipeline entrenado en RAVDESS Speech. Luego se mantuvieron congelados extractor, pooling y escalado, y se adaptó únicamente la cabeza logística con cantidades crecientes de hablantes target. En EMO-DB, *boredom* se mapeó a calma por afinidad operacional de bajo arousal; esta correspondencia no implica equivalencia psicológica completa.

IV. EXPERIMENTOS, RESULTADOS Y DISCUSIÓN

IV-A. Validación cruzada

La Tabla II resume los resultados speaker-independent. Con eGeMAPS, regresión logística superó a RF y MLP, aunque las diferencias entre folds fueron elevadas. El mean pooling de la última capa wav2vec mejoró a eGeMAPS, y LDA añadió aproximadamente tres puntos de BA. El salto principal surgió al usar estadísticas temporales multicapa: `average_mean_std` alcanzó 0.736 ± 0.049 .

Cuadro II: Balanced accuracy en validación cruzada speaker-independent. SD: desviación entre cinco outer folds.

Configuración	BA	SD
eGeMAPS + RF	0.472	0.050
eGeMAPS + LR	0.493	0.069
eGeMAPS + RFECV + LR	0.475	0.062
wav2vec última capa + LR	0.552	0.071
wav2vec + LDA + LR	0.584	0.050
multicapa avg. mean-std + LR	0.736	0.049
multicapa mezcla mean-std	0.716	0.047
multicapa promedio + atención	0.680	0.062
multicapa mezcla + atención	0.677	0.072

RFECV no mejoró el baseline completo de eGeMAPS y quedó 1.8 puntos por debajo de la regresión logística con las 88 features. Además, los subconjuntos seleccionados cambiaron de un outer fold a otro, por lo que la reducción de dimensionalidad no fue estable ni aportó una mejora

reproducibile. En consecuencia, RFECV se interpretó como una herramienta exploratoria y no como una mejora efectiva del pipeline final.

La comparación por fold, presentada en la Figura 1, aporta dos conclusiones. Primero, `average_mean_std` obtuvo el mejor rendimiento en tres de los cinco folds, mantuvo el mayor promedio global y presentó el mejor peor fold, con valores entre 0.672 y 0.801. Segundo, las variantes con atención mostraron mayor sensibilidad a la inicialización: el desvío medio de BA entre semillas fue de aproximadamente 0.037, frente a 0.024 para la mezcla aprendida sin atención. Esto refuerza la idea de que, en un régimen de pocos hablantes, la simplicidad del pooling fijo actúa como una regularización efectiva.

IV-B. Evaluación final y análisis de errores

Entrenado sobre todo development, el modelo final alcanzó BA 0.828, macro-F1 0.809 y accuracy 0.817 en 240 audios de cuatro actores no vistos. En el mismo test, RF-eGeMAPS obtuvo BA 0.523 y LR-eGeMAPS 0.555. La mejora absoluta del modelo SSL sobre el baseline obligatorio fue 0.305.

La matriz de confusión completa se presenta en la Figura 3. Enojo, miedo, disgusto y sorpresa fueron reconocidos con recall entre 0.875 y 1.0. La principal dificultad fue tristeza, con recall 0.50: ocho de sus 32 ejemplos se confundieron con calma. Alegría obtuvo recall 0.656 y siete ejemplos se asignaron a sorpresa. Ambos patrones son coherentes con fronteras afectivas que comparten arousal: tristeza y calma tienden a baja activación, mientras que alegría y sorpresa presentan mayor energía. Neutral logró recall perfecto, pero precisión 0.615, porque absorbió emisiones de otras clases de baja activación.

La variabilidad por hablante, detallada en la Figura 2, persiste aun usando la misma representación final. En development, las predicciones OOF por actor se concentran alrededor de una línea media cercana a 0.74, pero con casos que descienden por debajo de 0.50. En test, los cuatro actores reservados obtuvieron BA entre 0.672 y 0.938. Por ello, la diferencia positiva entre test (0.828) y la media de CV (0.736) no se interpreta como una mejora garantizada por entrenar con más datos, sino como una combinación entre mayor tamaño de entrenamiento y distinta dificultad de los hablantes reservados.

IV-C. Transferencia y adaptación

La Tabla III resume la transferencia zero-shot. El cambio de dominio degradó el rendimiento en ambos corpus target, pero wav2vec mantuvo una ventaja clara sobre eGeMAPS: BA 0.458 frente a 0.349 en RAVDESS Song y 0.483 frente a 0.217 en EMO-DB. Esto indica que la representación SSL conserva información emocional más portable incluso cuando la cabeza fue entrenada únicamente sobre habla actuada en inglés norteamericano.

Cuadro III: Balanced accuracy zero-shot en dominios target.

Dominio target	eGeMAPS	wav2vec temporal
EMO-DB	0.217	0.483
RAVDESS Song	0.349	0.458

El compromiso entre adaptación y retención se visualiza en la Figura 4. En EMO-DB, wav2vec fue la opción más eficiente: con un único hablante target ya ganó cerca de 0.21 puntos de BA y con ocho hablantes alcanzó una mejora acumulada de aproximadamente 0.39, a costa de una caída cercana a 0.04 en el dominio fuente. En RAVDESS Song, las ganancias fueron menores, pero crecieron de forma sostenida hasta alrededor de 0.18 con 19 hablantes. eGeMAPS también mejoró con adaptación, aunque se mantuvo claramente por debajo y con una pérdida relativa similar o mayor en RAVDESS Speech. En conjunto, estos resultados muestran que la representación SSL transfiere mejor y que la adaptación de cabeza permite capturar información del nuevo dominio sin modificar el extractor congelado.

V. CONCLUSIÓN Y TRABAJO FUTURO

Las representaciones wav2vec congeladas superaron a eGeMAPS en la clasificación speaker-independent de ocho emociones. El mejor resultado no provino del modelo más complejo, sino de promediar estadísticas temporales de los 13 niveles y entrenar una regresión logística. Esta combinación alcanzó BA 0.736 en CV y 0.828 en test, con errores concentrados en pares acústicamente próximos. RFECV no aportó una mejora consistente y, además, mostró inestabilidad entre folds, lo que refuerza la conveniencia de conservar la representación completa cuando el beneficio de selección no es claro. La atención y la mezcla aprendida tampoco aportaron una mejora robusta, probablemente por la cantidad limitada de hablantes. En transferencia, wav2vec mostró mayor portabilidad y respondió mejor a la adaptación de cabeza.

Como trabajo futuro se propone ampliar la evaluación a más corpora y hablantes, estudiar fine-tuning parcial del encoder, incorporar representaciones log-Mel y explorar regularización explícita de identidad. También sería relevante adaptar de forma conjunta fuente y target para reducir el olvido observado durante la transferencia.

REFERENCIAS

- [1] F. Eyben, K. R. Scherer, B. W. Schuller, J. Sundberg, E. André, C. Busso, L. Y. Devillers, J. Epps, P. Laukka, S. S. Narayanan, and K. P. Truong, "The geneva minimalistic acoustic parameter set (GeMAPS) for voice research and affective computing," *IEEE Transactions on Affective Computing*, vol. 7, no. 2, pp. 190–202, 2016.
- [2] A. Baeovski, H. Zhou, A. Mohamed, and M. Auli, "wav2vec 2.0: A framework for self-supervised learning of speech representations," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 12 449–12 460.
- [3] L. Pepino, P. Riera, and L. Ferrer, "Emotion recognition from speech using wav2vec 2.0 embeddings," in *Proceedings of Interspeech 2021*, 2021, pp. 3400–3404.
- [4] C. Doğdu, T. Kessler, D. Schneider, M. Shadaydeh, and S. R. Schweinberger, "A comparison of machine learning algorithms and feature sets for automatic vocal emotion recognition in speech," *Sensors*, vol. 22, no. 19, p. 7561, 2022.
- [5] S. R. Livingstone and F. A. Russo, "The ryerson audio-visual database of emotional speech and song (RAVDESS): A dynamic, multimodal set of facial and vocal expressions in north american english," *PLOS ONE*, vol. 13, no. 5, p. e0196391, 2018.
- [6] F. Eyben, M. Wöllmer, and B. Schuller, "opensmile: The munich versatile and fast open-source audio feature extractor," in *Proceedings of the 18th ACM International Conference on Multimedia*, 2010, pp. 1459–1462.
- [7] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. VanderPlas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, "Scikit-learn: Machine learning in python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [8] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Köpf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai, and S. Chintala, "Pytorch: An imperative style, high-performance deep learning library," in *Advances in Neural Information Processing Systems*, vol. 32, 2019, pp. 8024–8035.
- [9] T. Wolf, L. Debut, V. Sanh, J. Chaumond, C. Delangue, A. Moi, P. Cistac, T. Rault, R. Louf, M. Funtowicz, J. Davison, S. Shleifer, P. von Platen, C. Ma, Y. Jernite, J. Plu, C. Xu, T. L. Scao, S. Gugger, M. Drame, Q. Lhoest, and A. M. Rush, "Transformers: State-of-the-art natural language processing," in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 2020, pp. 38–45.
- [10] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [11] F. Burkhardt, A. Paeschke, M. Rolfes, W. F. Sendlmeier, and B. Weiss, "A database of german emotional speech," in *Proceedings of Interspeech 2005*, 2005, pp. 1517–1520.

APÉNDICE A

VISUALIZACIONES COMPLEMENTARIAS

Las siguientes figuras amplían los resultados discutidos en el cuerpo principal.




Figura 1: Rendimiento de las cuatro representaciones temporales por outer fold (izquierda) y sensibilidad a la inicialización de las configuraciones aprendidas (derecha). La representación `average_mean_std` alcanza el mayor promedio y el mejor peor fold, mientras que las variantes con atención presentan mayor dispersión entre semillas.




Figura 2: Balanced accuracy por actor para la representación final. Los círculos corresponden a predicciones OOF de development y las cruces a los cuatro actores del test final. La dispersión muestra que el rendimiento speaker-independent depende de la dificultad particular de cada hablante.




Figura 3: Matrices de confusión de los modelos evaluados sobre test. Cada celda combina recall normalizado por clase verdadera y conteo absoluto, permitiendo identificar las confusiones dominantes y su frecuencia efectiva.




Figura 4: Trade-off entre ganancia de BA en el dominio target y cambio de BA en RAVDESS Speech al adaptar únicamente la cabeza logística. Las etiquetas indican la cantidad de hablantes target utilizados. El cuadrante superior derecho representaría mejora target sin pérdida en el dominio fuente.