

Reconocimiento de emociones en el habla mediante features expertas y representaciones SSL multicapa

Alejandro Garcia Giachetta y Franco Agustín Sandri - I302, Universidad de San Andrés
agarciagiachetta@udesa.edu.ar - fsandri@udesa.edu.ar




Motivo

Un modelo de SER puede parecer excelente y en realidad estar memorizando voces particulares: prosodia, energía y timbre dependen tanto de la emoción como de quién habla. Este trabajo compara features acústicas expertas y representaciones autosupervisadas bajo una evaluación estrictamente independiente de hablante.


¿Qué son las características acústicas?

Las características acústicas son functionals estadísticos calculados sobre descriptores de bajo nivel de la señal —F0, RMS, MFCC— que resumen su comportamiento espectral y prosódico en un vector de dimensión fija.



Metología


Mezcla aprendida de capas + atención temporal (learned_layers_attention_statistics)



Pipeline learned_layers_attention_statistics sobre wav2vec 2.0



Validación

Comparación speaker-independent de modelos y representaciones




Resultados

BA de 0.736 ± 0.049 en CV y 0.828 en test — mejora de $+0.305$ sobre el baseline. La principal confusión es tristeza-calma (recall 0.50), coherente con su bajo arousal compartido. wav2vec transfiere mejor que eGeMAPS a otros dominios (EMO-DB, RAVDESS Song).




Datasets

RAVDESS para entrenar y evaluar bajo protocolo speaker-independent; EMO-DB y RAVDESS Song para medir transferencia zero-shot y con adaptación de cabeza.




Wav2Vec

wav2vec 2.0 es un encoder autosupervisado que aprende representaciones de habla prediciendo unidades discretas enmascaradas a partir de audio crudo, y aquí se usa congelado, extrayendo sus 13 niveles internos (768 dims cada uno) como features para la clasificación de emociones.



¿Qué aprende la atención?

Los pesos de atención temporal siguen de cerca la envolvente de energía (RMS) de la señal, más que rasgos específicos de la emoción. Esto explica por qué la atención no mejoró la generalización: aprende "dónde está lo fuerte", no "dónde está lo emocional".



Discusión

- La simplicidad ganó: promediar estadísticas temporales de las 13 capas + regresión logística superó a arquitecturas más complejas.
- RFECV fue inestable entre folds y no mejoró la representación completa de eGeMAPS.
- Atención y mezcla aprendida tampoco aportaron mejoras robustas — probablemente por la limitada cantidad de hablantes.
- wav2vec transfiere mejor que eGeMAPS a otros dominios y responde mejor a la adaptación de cabeza.
- Trabajo futuro: más corpora y hablantes, fine-tuning parcial del encoder, features log-Mel, regularización de identidad.